# Indexation de documents

#### Création d'un index



Création d'un index avec l'API REST « Create Index » :

```
PUT /bibliotheque/
```

Création d'un index avec des settings :

```
PUT /bibliotheque/
{ "settings" : {"index" : {
    "number_of_shards" : 8,
    "number_of_replicas": 2
}}}
```

• Les index sont automatiquement créés s'ils n'existent pas au moment de l'indexation des documents

#### **Modification d'un index**



Mise à jour des settings d'un index avec l'API REST «Update Settings » :

```
PUT /bibliotheque/_settings
{ "index" : {
    "number_of_replicas": 6,
    "refresh_interval": "30s"
}}
```

- Principaux settings :
  - number of replicas: Nombre de réplicas
  - refresh\_interval : Intervalle de temps (en secondes) de rafraîchissement de l'index

## **Suppression d'un index**



Suppression d'un index avec l'API REST :

```
DELETE /bibliotheque/
```

Suppression de plusieurs index

```
DELETE /index1,index2,index3/
```

• Suppression de tous les index

```
DELETE /_all
DELETE /*
```

• Il est possible d'empêcher la suppression de tous les index en configurant dans le fichier elasticsearch.yml:

```
action.destructive_requires_name: true
```

#### Indexation de documents avec l'API Rest



- L'API REST permet d'indexer un document au format JSON
  - En utilisant la méthode HTTP PUT et en précisant un identifiant de document :

```
PUT /bibliotheque/livre/1
{"titre": "7 ans après...", "auteurs": "Guillaume Musso", "prix": 20.80}
{ "created":true, "_index":"bibliotheque", "_type":"books", "_id":"1",
"_version":1,
"_shards": { ... }}
```

• En utilisant la méthode HTTP POST pour qu'un identifiant de document soit automatiquement généré :

```
POST /bibliotheque/livre
{"titre": "7 ans après...", "auteurs": "Guillaume Musso", "prix": 20.80}

{ "created":true, "_index":"bibliotheque", "_type":"books",

"_id":"AVGRV_usnjDD0CQltR_N", "_version":1,

"_shards": { ... }}
```

## Mise à jour d'un document 1/3



- Mettre à jour un document consiste à réindexer le document
  - Nécessite de connaître son identifiant
- Incrémente le numéro de version automatiquement
- Annule et **remplace** la version précédente du document
  - Nécessite de réindexer la totalité du document

```
PUT /bibliotheque/livre/1 { "titre": "7 ans après.....", "prix": 20.80}
```

## Mise à jour d'un document 2/3



- L'API REST « Update » permet de mettre à jour un ou plusieurs champs d'un document via script
- Permet :
  - d'ajouter de nouveaux champs,
  - d'ajouter de nouvelles valeurs à un champ existant,
  - de supprimer un champ existant,
  - supprimer le document si une condition est vérifiée...
- Comme indiqué, réindexe totalement le document et nécessite donc que la source du document soit activée.
- Utilise en interne la version du document pour détecter les accès concurrents (voir plus loin pour plus de détails sur le fontionnement du champ version)

## Mise à jour d'un document 3/3



#### Deux syntaxes:

• A base de script :

- map ctx permet d'accéder à plusieurs infos ( index, type, id ...)
- nécessite d'autoriser l'exécution de scripts: script.inline: true
- suppression de champs possible:

```
"script" : "ctx._source.remove(\"prix\")"
```

• A base de document partiel doc :

```
POST /bibliotheque/livre/1/_update
{ "doc" : {"prix" : 25 }}
```

- mergé avec le document actuel
- pas de suppression possible

## **Suppression d'un document**



• L'API REST permet de supprimer un document

DELETE /bibliotheque/livre/1

#### API Bulk 1/3



• Endpoint bulk dédié aux opérations en lot

```
POST /_bulk { ... }
```

- Beaucoup plus performante pour un grand nombre d'opérations
  - Exemple: Batch
- Format spécifique des données :

```
action + meta_donnees\n
source_optionelle\n
action + meta_donnees\n
source_optionelle\n
...
```

- En sortie : JSON contenant le résultat de chaque action
  - code réponse HTTP
  - éventuellement, message d'erreur

#### API Bulk 2/3



- Opérations possibles : index / create / update / delete
- Source inutile pour delete
- Exemple de données en entrée :

```
{ "create" : { "_index" : "bibliotheque", "_type" : "livre", "_id" : "43" } }
{ "auteur" : "Victor Hugo", "titre":"Les Misérables" }
{ "delete" : { "_index" : "bibliotheque", "_type" : "livre", "_id" : "2" } }
{ "update" : {"_index" : "bibliotheque", "_type" : "dvd", "_id" : "1"} }
{ "doc" : {"lang" : "fr"} }
```

#### API Bulk 3/3



• Réponse :

```
[{ "create": {
     "_index": "bibliotheque",
     "_type": "livre",
     "_id": "43",
     "_version": 1,
     "status": 201 }
},{ "delete": {
     "_index": "bibliotheque",
     "_type": "livre",
     "_id": "2",
     "_version": 1,
     "status": 404, "found": false }
},{ "update": {
     "_index": "bibliotheque",
     "_type": "dvd",
     "_id": "43",
     "status": 404, "error": {
           "type": "document_missing_exception",
           "reason": "[dvd][1]: document missing",
           "index": "bibliotheque",
           "shard": "-1" }}
},...]
```

#### Identifiant de document



- Tous les documents ont un identifiant
  - Lors de l'indexation du document, l'identifiant peut être spécifié (PUT) ou généré automatiquement (POST)
  - L'identifiant et le type de document permettent d'identifier un document dans un index
  - L'id est retourné dans le champ id lors d'une recherche
  - L'id est utilisé pour récupérer un document dans une requête GET
  - Le champ \_uid est l'identifiant unique dans l'index \_uid = \_type + id
- Utiliser autant que possible un id métier
  - Toutes les opérations sur un document passent par l'identifiant
  - Sans l'identifiant, il faut préalablement faire une recherche pour retrouver un document

#### **Version**



- Les documents sont automatiquement versionnés lors de l'indexation
  - Le numéro de version commence à 1
  - Il est incrémenté à chaque nouvelle indexation du document
  - Le numéro de version est retourné lors de l'indexation mais pas lors des recherches (par défaut)
- Il est possible de gérer manuellement les numéros de version
  - En précisant les paramètres version et version type=external

## **Version | Optimistic Concurrency Control 1/4**



- Optimistic Concurrency Control
  - Elasticsearch n'a pas de support de transactions
  - Lors d'une indexation, il est possible de fournir un numéro de version via le paramètre version
  - Elasticsearch vérifiera si le document est dans la version indiquée avant d'effectuer l'opération demandée
  - Utile pour simuler une transaction de type readthenupdate

## **Version | Optimistic Concurrency Control 2/4**



Exemples de requêtes illustrant l'Optimistic Concurrency Control

Indexation sans version (v2 → v3;)

```
PUT /bibliotheque/livre/1 {...}
{"_index": "bibliotheque", "_type": "livre", "_id":"1", "_version":3,
"created":false}
```

• Indexation v2 (erreur de type version conflict engine exception)

```
PUT /bibliotheque/livre/1?version=2 {...}

{"error": {
    "type": "version_conflict_engine_exception",
    "reason": "[livre][1]: version conflict, current [3], provided [2]",
    "index": "bibliotheque", "shard": "3"
}, "status": 409}
```

Indexation v3 (v3 → v4)

```
PUT /bibliotheque/livre/1?version=3 {...}

{"_index": "bibliotheque", "_type": "livre", "_id": "1", "_version":4,

"created": false}
```

## **Version | Optimistic Concurrency Control 3/4**



La version actuelle est 4...

• Suppression v3 (erreur de type version\_conflict\_engine\_exception)

```
DELETE /bibliotheque/livre/1?version=3
{"error":{"reason": "[livre][1]: version conflict, current [4], provided [3]"
... }}, "status":409}
```

## **Version | Optimistic Concurrency Control 4/4**



- Exemple de requête illustrant le version type=external
  - Impose version > version stockée dans l'index

```
PUT /bibliotheque/livre/1?version_type=external&version=4
{"titre": "Spring Batch in Action"}
{"_index": "bibliotheque", "_type": "livre", "_id": "1", "_version": 4,
"created": false}
```

#### Refresh



#### Near Real Time

- Il existe un léger décalage entre le moment où un document est indexé et le moment où il est disponible et remonte en résultat de recherche
- Ce laps de temps est configuré à 1 seconde par défaut pour les index
- Configurable au niveau de chaque index avec le setting refresh interval
- Avant une indexation en masse (\_bulk), il est conseillé d'augmenter le refresh interval pour éviter trop de rafraîchissements de l'index

## Refresh et segments Lucene



- Avant d'être transmis à Lucene, les documents indéxés sont analysés et stockés dans un buffer mémoire:
  - à ce stade, ces documents ne peuvent pas être recherchés.
- Ce buffer mémoire est accompagné d'un fichier TransLog qui a le même cycle de vie et qui est écrit dans le cache disque système. Il sert à persister les commandes ayant rempli le buffer.
- Ce buffer mémoire est flushé dans un segment Lucene lorsque:
  - le buffer est plein
  - lors d'un reopen Lucene
  - sur un refresh ElasticSearch:
    - sans commit Lucene,
    - déclenché selon valeur du index.refresh\_interval ou via l'API\_refresh
  - sur un flush ElasticSearch:
    - o provoque un commit Lucene,
    - déclenché automatiquement par Elasticsearch ou via l'API \_\_flush

## Segments et merges Lucene 1/2

- Un segment Lucene est un inverted vector index autosuffisant et immuable (jamais de suppression)
- Les segments augmentent en nombre et **consomment** de plus en plus de **ressources** (pointeurs sur fichiers, caches, memoire...)
- Pour pallier ce problème, Elasticsearch choisit de merger régulièrement des segments Lucene
- Ces opérations de merge répondent à une merge policy choisie optionnellement à la création de l'index. (réglage expert)
- Un **merge** consiste à:
  - Supprimer plusieurs segments
  - Supprimer les caches associés
  - Construire un segment immuable plus grand pour contenir les segments précédents sans reprendre les documents marqués détruits

## Segments et merges Lucene 2/2



- L'opération de merge peut être coûteuse, jouer sur les paramètres suivants au niveau du noeud pour maîtriser ce coût:
  - positionner indices.store.throttle.type to merge
  - positionner indices.store.throttle.max\_bytes\_per\_sec à xmb

Voir cette simulation des merges Lucene pour comprendre:

https://www.youtube.com/watch?v=YW0bOvLp72E

#### Refresh forcé



- Certaines opérations acceptent un paramètre refresh=true pour rafraîchir directement l'index après l'opération
  - Utile pour les tests d'intégrations
  - A utiliser judicieusement, car très coûteux

PUT /bibliotheque/livre/1?refresh=true

{"titre":"Spring Batch in Action"}

## **Operation Type**



- Lors d'une indexation, il est possible de préciser le paramètre op type=create
- Permet d'indexer un document uniquement s'il n'existe pas déjà

```
PUT /bibliotheque/livre/1?op_type=create
{"titre":"Spring Batch in Action"}
{ "error": {
    "type": "document_already_exists_exception",
    "reason": "[livre][1]: document already exists",
    "index": "bibliotheque", "shard": "2"
}, "status": 409 }
```

Peut aussi s'écrire avec la notation \_create

```
PUT /bibliotheque/livre/1/_create
{"titre":"Spring Batch in Action"}
```

#### **Autres fonctionnalités**



- Lors d'une indexation de document, il est aussi possible de préciser
  - Le routing à utiliser, pour que le document soit ajouté à un shard précis de l'index
  - Le document parent du document qu'on s'apprête à indexer, et ainsi permettent les recherches parent/child
  - Le consistency à utiliser, pour avoir la main sur le nombre minimum de shards/replicas dans lequel le document doit être écrit: one, quorum (par defaut), all.
  - Un timeout, au delà duquel une erreur sera renvoyée si l'opération prend plus de temps à s'exécuter

#### Alias d'index



- Il est possible de créer des alias sur les index
  - Un alias pointe vers un ou plusieurs autres index
  - La création et la suppression des alias se fait via une API Rest

```
POST /_aliases
{"actions" : [{ "add" : { "index" : "bibliotheque", "alias" : "znk" } }]}
PUT bibliotheque/_aliases/znk
GET bibliotheque/_aliases
```

- Il existe un alias par défaut : all
- Permet différents cas d'utilisations
  - Alias « current » sur le dernier index de logs
  - Réunir plusieurs index fréquemment utilisés ensemble
- Fonctionnalités avancées
  - Filtre : alias sur un index filtré sur une requête
  - Route : spécifie le routage sur les shards de l'index



## TP2